UNIVERSIDAD SANTO TOMÁS · SECCIONAL TUNJA

Facultad de Ingeniería de Sistemas

PROYECTO INTEGRADOR

Análisis de datos reales con Big Data en Python

Modalidad: Equipos de máximo 3 estudiantes

Entrega de avance: jueves 5 de noviembre de 2026

Entrega final y socialización: jueves 19 de noviembre de 2026

1. Propósito del proyecto

El proyecto integrador cierra el curso con un trabajo aplicado a un **contexto real**. Cada equipo selecciona un conjunto de datos público, construye en **Python** un flujo de datos completo (ingesta, limpieza, procesamiento, análisis y visualización) y presenta los resultados en un dashboard interactivo que responde a preguntas concretas de un sector.

1.1 Contexto reutilizable en otras electivas

El contexto y el dataset que elija el equipo pueden usarse en otros espacios académicos. Cada espacio califica su propio producto: en Big Data se evalúa el flujo de datos, la limpieza, el procesamiento, el análisis y el dashboard. Si el equipo reutiliza el contexto, debe declararlo en el documento e indicar qué parte del trabajo corresponde a este curso.

2. Temáticas del syllabus que se deben aplicar

El proyecto debe aplicar **las dos temáticas obligatorias y al menos una temática electiva**, para un mínimo de tres.

Tipo	Temática (unidad del syllabus)	Qué se espera ver en el proyecto
Obligatoria 1	Procesamiento con Apache Spark y PySpark; Spark SQL (Unidad 3)	Lectura del dataset con PySpark, filtros, agregaciones con groupBy y al menos una consulta con Spark SQL o un join entre tablas. Verificación de resultados con count().
Obligatoria 2	Python para análisis y representación de datos: Pandas, NumPy, Matplotlib/Seaborn, Plotly, Streamlit, estadística descriptiva y correlación (Unidad 5)	Limpieza y transformación documentadas, estadística descriptiva, análisis de correlación y dashboard en Streamlit con gráficos de Plotly.
Electiva A	Bases de datos NoSQL con MongoDB (Unidad 2)	Carga de una parte de los datos (por ejemplo, la capa cruda o un subconjunto semiestructurado) en MongoDB Atlas, con consultas que usen operadores y una agregación.
Electiva B	Arquitectura y gobierno: Data Lake, Data Warehouse, Lakehouse, capas bronce/plata/oro (Unidades 1 y 4)	Diagrama de la arquitectura propuesta y organización real de los datos en capas, con un diccionario de datos y un responsable por fuente.
Electiva C	ETL/ELT y Delta Lake (Unidad 4)	Pipeline reproducible por etapas; si se usa Delta Lake, demostrar una transacción y el versionado (time travel).
Electiva D	Streaming (Unidad 3)	Simulación de llegada de datos por lotes o con Structured Streaming, con una métrica que se actualice.

Tipo	Temática (unidad del syllabus)	Qué se espera ver en el proyecto
Electiva E	Calidad de datos, normatividad y valor (Unidad 6)	Indicadores de calidad antes y después de la limpieza (alineados con ISO/IEC 5259), análisis de datos personales frente a la Ley 1581 de 2012 y una estimación sencilla de valor o ROI.

3. Requisitos del dataset

3.1 Condiciones obligatorias

- **Real y público**, con fuente identificable, fecha de descarga y licencia o términos de uso citados.
- **Volumen que justifique Big Data:** mínimo de 100 00 registros. Se permite combinar varias tablas o periodos del mismo origen para alcanzar el volumen.
- **Requiere limpieza real:** valores nulos, duplicados, formatos inconsistentes, tipos de dato incorrectos, categorías mal escritas o valores atípicos. No se aceptan datasets ya depurados con fines de enseñanza (por ejemplo, Titanic, Iris o Gapminder).
- **Permite responder preguntas de negocio o de impacto social** relevantes para un sector (salud, educación, transporte, agro, ambiente, gobierno, comercio, etc.).
- **Sin datos personales identificables.** Si el dataset los contiene, deben eliminarse o seudonimizarse y explicarse el tratamiento conforme a la Ley 1581 de 2012.

3.2 Fuentes sugeridas

Las siguientes fuentes son públicas y contienen datos reales. Cada equipo debe verificar el volumen y la licencia del conjunto específico que descargue, ya que los portales actualizan sus datasets con frecuencia.

Fuente	Ejemplos de datasets	Posibles preguntas de análisis
Portal de Datos Abiertos de Colombia (datos.gov.co)	Contratación pública SECOP II; casos de COVID-19 del INS; datos hidrometeorológicos del IDEAM; siniestros viales	¿Qué entidades concentran la contratación directa? ¿Cómo varía la precipitación en Boyacá por temporada? ¿En qué franjas ocurren más siniestros?
ICFES – DataIcfes (icfes.gov.co)	Resultados Saber 11 y Saber Pro por periodo	¿Qué factores socioeconómicos se asocian al puntaje? ¿Cómo se compara Boyacá con el promedio nacional?
DANE (dane.gov.co)	SIPSA: precios y abastecimiento mayorista de alimentos; microdatos de encuestas	¿Cómo varían los precios de la papa y otros productos de Boyacá en las centrales de abasto?
Banco Mundial (data.worldbank.org)	Indicadores de Desarrollo Mundial (WDI)	¿Qué indicadores se correlacionan con el acceso a internet o la escolaridad en América Latina?
NYC Taxi & Limousine Commission	Registros de viajes de taxi (archivos Parquet mensuales)	¿Cómo varían la demanda y la tarifa por hora, día y zona?

Fuente	Ejemplos de datasets	Posibles preguntas de análisis
GroupLens – MovieLens	Calificaciones de películas (25 millones de registros)	¿Qué géneros tienen mejor valoración y cómo cambia en el tiempo?
Kaggle – Olist Brazilian E-Commerce	Pedidos, pagos, reseñas y vendedores en varias tablas relacionadas	¿Qué factores se asocian a las malas reseñas? ¿Cuánto tarda la entrega por región?
OpenAQ (openaq.org)	Mediciones de calidad del aire de estaciones en Colombia y otros países	¿En qué horas y meses se superan los niveles de PM2.5 recomendados?

Un equipo puede proponer otra fuente si cumple con las condiciones del numeral 3.1. La docente aprueba el dataset antes de que el equipo avance.

4. Herramientas permitidas

Todo el procesamiento se hace en **Python**, en Google Colab o en un entorno local, con las librerías vistas en clase:

Propósito	Librerías
Procesamiento distribuido	pyspark (DataFrames y Spark SQL)
Análisis y limpieza	pandas, numpy
Visualización	matplotlib, seaborn, plotly
Dashboard	streamlit (obligatorio), con gráficos de plotly
NoSQL (si eligen la Electiva A)	pymongo con MongoDB Atlas
Lakehouse (si eligen la Electiva C)	delta-spark

Power BI puede usarse como complemento, pero **no reemplaza el dashboard en Streamlit**. Cualquier otra librería requiere aprobación previa de la docente.

4.1 Uso de inteligencia artificial

Se permite usar herramientas de IA como apoyo, con dos condiciones: el documento debe incluir una **declaración de uso de IA** (qué herramienta, para qué tarea y qué se verificó o corrigió), y **cada integrante debe poder explicar cualquier parte del código y del análisis** durante la socialización. Si un integrante no puede explicar el trabajo de su equipo, su nota individual se ajusta según la rúbrica de socialización.

5. Tareas del proyecto

Tarea	Descripción
T1. Definición del contexto	Describir el sector, el problema y los usuarios de la información. Formular entre 3 y 5 preguntas de análisis concretas y medibles.

Tarea	Descripción
T2. Selección y descripción del dataset	Fuente, licencia, fecha de descarga, volumen (filas, columnas, MB), diccionario de datos y una evaluación inicial de calidad.
T3. Arquitectura del flujo de datos	Diagrama de fuentes, ingesta, almacenamiento (capas cruda, limpia y analítica), procesamiento y consumo (dashboard).
T4. Ingesta	Carga reproducible del dataset desde su origen (descarga por código o API), lectura con PySpark y, si aplica, carga en MongoDB.
T5. Limpieza y transformación	Tratamiento de nulos, duplicados, tipos, formatos, categorías y atípicos, con la justificación de cada decisión y una tabla de métricas antes/después.
T6. Procesamiento con PySpark	Filtros, agregaciones, joins o consultas Spark SQL que alimenten el análisis. Verificar resultados con count() y show(n).
T7. Análisis exploratorio y estadístico	Estadística descriptiva, distribuciones, correlación y comparaciones entre grupos o periodos. Cada hallazgo debe citar cifras.
T8. Dashboard en Streamlit	Indicadores clave (KPI), mínimo cuatro visualizaciones de Plotly y al menos dos filtros interactivos. Debe responder las preguntas de T1.
T9. Análisis final y recomendaciones	Responder cada pregunta de T1 con evidencia, señalar limitaciones del dataset y proponer recomendaciones para el sector.
T10. Comunicación	Informe, video de demostración y socialización en equipo.

6. Cronograma y entregas

Fecha	Hito	Qué se entrega
Jueves 22 de octubre (sugerida)	Inscripción del equipo y del dataset	Nombre de los integrantes (máximo 3), dataset propuesto con enlace y 3 a 5 preguntas de análisis. La docente aprueba o pide ajustes.
Jueves 5 de noviembre de 2026	**Entrega de avance (parcial)**	Documento de avance, notebook con ingesta, limpieza y primeros resultados, y prototipo del dashboard. Ver numeral 7.
Jueves 19 de noviembre de 2026	**Entrega final y socialización**	Informe final, repositorio de código, dashboard funcional, video de máximo 3 minutos y diapositivas. Ver numeral 8.

Las entregas se hacen por el campus virtual antes de las 11:59 p. m. del día indicado. Un solo integrante sube los archivos en nombre del equipo, y todos los archivos deben llevar el nombre completo de cada integrante.

7. Entrega de avance (5 de noviembre)

7.1 Archivos que se entregan

- **Documento de avance** en PDF (máximo 8 páginas sin contar portada ni anexos).

- **Notebook (.ipynb)** con las celdas ejecutadas y sus resultados visibles: ingesta, limpieza y procesamiento inicial con PySpark.
- **Prototipo del dashboard:** mockup, captura o primera versión en Streamlit con al menos dos visualizaciones.
- **Enlace al repositorio** (GitHub o Google Drive) con la estructura de carpetas inicial.

7.2 Contenido esperado del documento de avance

- **Portada:** Título del proyecto, integrantes, curso, docente y fecha.
- **1. Contexto y problema:** Sector, problema que se aborda y a quién le sirve el análisis (máximo una página).
- **2. Preguntas de análisis:** Entre 3 y 5 preguntas concretas y medibles.
- **3. Descripción del dataset:** Fuente con enlace y fecha de descarga, licencia, volumen (filas, columnas, MB) y diccionario de datos (columna, tipo, descripción, ejemplo).
- **4. Diagnóstico de calidad:** Tabla con nulos, duplicados, tipos incorrectos y atípicos por columna, obtenida con código.
- **5. Arquitectura propuesta:** Diagrama del flujo de datos y explicación de las capas y herramientas.
- **6. Avance de limpieza y procesamiento:** Decisiones tomadas hasta la fecha, con su justificación, y primeros resultados con PySpark (capturas o tablas).
- **7. Temáticas del syllabus:** Cuáles se aplican (obligatorias y electiva) y cómo.
- **8. Prototipo del dashboard:** Boceto o captura y descripción de las visualizaciones previstas.
- **9. Plan de trabajo:** Tareas pendientes, responsable por integrante y fechas hasta el 19 de noviembre.
- **Referencias:** Normas APA 7.ª edición.

8. Entrega final (19 de noviembre)

8.1 Archivos que se entregan

- **Informe final** en PDF (máximo 20 páginas sin contar portada ni anexos).
- **Repositorio de código** con: notebooks ejecutados, script de la app de Streamlit (app.py), archivo requirements.txt, README con instrucciones para ejecutar el proyecto y carpeta de datos o enlace de descarga.
- **Dashboard funcional:** enlace público (Streamlit Community Cloud) o instrucciones para ejecutarlo localmente.
- **Video de demostración** de máximo 3 minutos (numeral 9).
- **Diapositivas** de la socialización en PDF o PPTX (numeral 10).

8.2 Contenido esperado del informe final

- **Portada y resumen:** Título, integrantes y un resumen de máximo 200 palabras con el problema, el método y los principales hallazgos.

- **1. Introducción:** Contexto, problema, justificación y preguntas de análisis.
- **2. Objetivos:** Un objetivo general y entre tres y cinco específicos.
- **3. Dataset:** Fuente, licencia, volumen, diccionario de datos y consideraciones de datos personales (Ley 1581 de 2012).
- **4. Arquitectura y temáticas aplicadas:** Diagrama final del flujo de datos y explicación de cómo se aplicó cada temática del syllabus.
- **5. Limpieza y transformación:** Cada decisión con su justificación y la tabla de métricas de calidad antes y después (filas, nulos, duplicados, tipos corregidos).
- **6. Procesamiento con PySpark:** Consultas principales con su código, resultado y verificación (count()).
- **7. Análisis de resultados:** Estadística descriptiva, correlación y respuesta a cada pregunta de análisis con cifras y gráficos.
- **8. Dashboard:** Capturas, descripción de cada visualización y filtro, y qué pregunta responde cada uno.
- **9. Conclusiones y recomendaciones:** Respuestas a las preguntas, recomendaciones para el sector, limitaciones del dataset y trabajo futuro.
- **10. Declaración de uso de IA:** Herramientas usadas, para qué y qué se verificó o corrigió.
- **11. Aportes de cada integrante:** Tabla con las tareas realizadas por cada persona.
- **Referencias y anexos:** Normas APA 7.ª edición; anexos con el diccionario completo y código adicional.

9. Lineamientos del video de demostración

Duración máxima: 3 minutos. Si el video supera ese tiempo, solo se califican los primeros 3 minutos.

- Deben participar todos los integrantes, con voz o en cámara.
- Grabación de pantalla con audio claro.
- Publicar en YouTube (no listado) o Google Drive con permiso de visualización, e incluir el enlace en el informe y en el README.
- No se aceptan videos solo con diapositivas: debe verse el código o el dashboard en funcionamiento.

10. Lineamientos de la socialización

- **Duración:** 10 minutos de presentación y 5 minutos de preguntas por equipo.
- **Diapositivas:** máximo 12, con letra de 20 puntos o más, pocas palabras por diapositiva y gráficos legibles.
- **Estructura sugerida:** problema y preguntas, dataset, arquitectura, limpieza, resultados principales, dashboard, conclusiones y recomendaciones.

- **Participación:** todos los integrantes presentan una parte. En la ronda de preguntas, la docente puede preguntar a cualquier integrante sobre cualquier parte del proyecto, incluido el código.
- **Nota individual:** la socialización tiene un componente individual (numeral 11.3), para reconocer el aporte real de cada persona.

11. Evaluación y rúbricas

Escala de cada criterio: **Excelente (4,5 – 5,0)**, **Bueno (3,5 – 4,4)**, **Básico (3,0 – 3,4)** e **Insuficiente (1,0 – 2,9)**. La nota de cada entrega es el promedio ponderado de sus criterios.

11.1 Rúbrica de la entrega de avance

Criterio	Peso	Excelente	Bueno	Básico	Insuficiente
Contexto y preguntas	15 %	Problema real y bien delimitado; 3 a 5 preguntas medibles y pertinentes.	Problema claro; preguntas pertinentes pero alguna poco medible.	Problema general; preguntas vagas.	Sin preguntas de análisis o sin relación con el dataset.
Dataset y diccionario	20 %	Cumple todos los requisitos (real, volumen, licencia); diccionario completo.	Cumple los requisitos; diccionario incompleto.	Falta un requisito (licencia o volumen).	Dataset no aprobado, de juguete o sin fuente.
Diagnóstico de calidad	20 %	Diagnóstico por columna obtenido con código, con cifras.	Diagnóstico con código pero incompleto.	Diagnóstico descrito sin evidencia de código.	Sin diagnóstico.
Avance técnico (ingesta, limpieza, PySpark)	30 %	Notebook ejecutado de principio a fin, limpieza justificada y consultas PySpark verificadas.	Notebook ejecutado con la mayor parte de la limpieza.	Avance parcial o con errores de ejecución.	Sin notebook o sin resultados visibles.
Arquitectura, prototipo y plan	15 %	Diagrama claro, prototipo con dos o más visualizaciones y plan con responsables.	Diagrama y prototipo básicos; plan sin responsables.	Falta el diagrama o el prototipo.	Faltan los tres.

11.2 Rúbrica de la entrega final

Criterio	Peso	Excelente	Bueno	Básico	Insuficiente
Limpieza y calidad de datos	15 %	Todas las decisiones justificadas, con métricas antes/después y verificación.	Limpieza completa con justificación parcial.	Limpieza mínima o sin métricas.	Datos sin limpiar o decisiones incorrectas.
Procesamiento con PySpark	15 %	Filtros, agregaciones y joins o Spark SQL correctos y verificados con count().	Consultas correctas sin verificación.	Consultas básicas o con errores menores.	Sin PySpark o con errores que invalidan resultados.
Temática electiva aplicada	10 %	Aplicada a fondo e integrada al flujo (ej.: MongoDB con agregaciones, capas con diccionario).	Aplicada correctamente pero aislada del flujo.	Aplicada de forma superficial.	No se aplica.
Análisis de resultados	20 %	Cada pregunta respondida con cifras, estadística y correlación; interpretación crítica y limitaciones.	Preguntas respondidas con cifras; interpretación limitada.	Respuestas genéricas con pocas cifras.	No responde las preguntas.
Dashboard en Streamlit	15 %	Funciona, tiene KPI, cuatro o más gráficos de Plotly y dos o más filtros, y responde las preguntas.	Funciona y cumple los mínimos.	Funciona con menos visualizaciones o sin filtros.	No funciona o no se entregó.
Informe y repositorio	10 %	Informe completo y bien redactado; repositorio con README y requirements.txt que permite reproducir el proyecto.	Informe completo; repositorio sin instrucciones claras.	Informe incompleto o con errores de redacción frecuentes.	Sin informe o sin código.
Video de demostración	5 %	3 minutos o menos, sigue la estructura y muestra el dashboard en vivo.	Cumple el tiempo; falta una sección.	Solo diapositivas o audio deficiente.	No se entregó.

Criterio	Peso	Excelente	Bueno	Básico	Insuficiente
Diapositivas y socialización grupal	10 %	Presentación clara dentro del tiempo; todos participan; diapositivas legibles.	Clara, con algún desbalance en la participación.	Desorganizada o fuera de tiempo.	No se presentó.

11.3 Rúbrica de la socialización individual

Criterio	Excelente	Bueno	Básico	Insuficiente
Dominio del proyecto (50 %)	Explica con precisión cualquier parte del flujo y del código.	Explica su parte y la mayoría del proyecto.	Explica solo su parte, con dificultad.	No logra explicar su parte.
Respuesta a preguntas (30 %)	Responde con argumentos y cifras del proyecto.	Responde correctamente con algunos vacíos.	Respuestas generales.	No responde.
Comunicación (20 %)	Clara, fluida y dentro del tiempo.	Clara con pausas.	Lee las diapositivas.	No presenta.

12. Recomendaciones y errores que se deben evitar

- **Verificar los resultados con código, no a ojo.** show() muestra solo 20 filas por defecto; usar count() para saber el tamaño real del resultado y filter() para comprobar un caso puntual.
- **Cada cifra del análisis debe salir de un resultado propio,** con la celda que la produjo.
- **Un solo documento por entrega,** con el nombre de todos los integrantes en la portada y en el notebook.
- **Citar las fuentes** del dataset y de los conceptos (APA 7.ª edición).
- **Guardar copias intermedias** (capa limpia en Parquet o CSV) para no repetir todo el procesamiento en cada sesión de Colab.
- **Probar el dashboard en otro computador** antes de la entrega, a partir de las instrucciones del README.